1830

Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

«Московский государственный технический университет имени Н.Э. Баумана

(национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ	Информ	патика и системы упра	<u>вления</u>							
КАФЕДРА Системы обработки информации и управления										
C	тчёт по лаб	бораторной рабо	ге №2							
		о дисциплине: и машинного обучени	я»							
Выполнил:										
Студент группы 1	ИУ5Ц-81Б <u> </u>		Бабакулыев Ф.А.							
		(Подпись, дата)	(Фамилия И.О.)							
Проверил:										
	_		<u>Гапанюк Ю. Е.</u>							
		(Подпись, дата)	(Фамилия И.О.)							

Задание

- 1. Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
- 2. Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:
 - обработку пропусков в данных;
 - кодирование категориальных признаков;
 - масштабирование данных.

ЛР №2

Импорт библиотек

```
In [1]: import numpy as np
         import pandas as pd
         import seaborn as sns
         import matplotlib.pyplot as plt
         from pandas.plotting import scatter matrix
         import warnings
         warnings.filterwarnings('ignore')
         sns.set(style="ticks")
         *matplotlib inline
In [2]: data = pd.read_csv('country_vaccinations.csv')
In [3]: data.head()
           country iso_code
                             date total_vaccinations people_vaccinated people_fully_vaccinated
Out[3]:
                            2021-

    Albania

                        ALB
                                               0.0
                                                                0.0
                                                                                     NaN
                            01-10
                            2021-
         1 Albania
                        ALB
                                              NaN
                                                               NaN
                                                                                     NaN
                            01-11
                            2021-
         2 Albania
                        ALB
                                             128.0
                                                               128.0
                                                                                     NaN
                            01-12
                            2021-
         3 Albania
                        ALB
                                             188.0
                                                              188.0
                                                                                     NaN
                            01-13
                            2021-
                       ALB 01-14
         4 Albania
                                             266.0
                                                              266.0
                                                                                     NaN
In [4]: data.dtypes
Out[4]: country
                                                   object
         iso code
                                                   object
                                                   object
        date
         total_vaccinations
                                                  float64
        people_vaccinated
                                                  float64
         people_fully_vaccinated
                                                  float64
         daily vaccinations raw
                                                  float64
        daily vaccinations
                                                  float64
         total_vaccinations_per_hundred
                                                  float64
        people vaccinated per hundred
                                                  float64
        people_fully_vaccinated_per_hundred
                                                  float64
         daily_vaccinations_per_million
                                                  float64
         vaccines
                                                   object
        source_name
                                                   object
         source_website
                                                   object
        dtype: object
In [5]: | data.isnull().sum()
         # проверим есть ли пропущенные значения
```

```
Out[5]: country
                                                   0
        iso_code
                                                 272
        date
                                                   0
        total_vaccinations
                                                1214
        people vaccinated
                                                1615
        people fully vaccinated
                                                2277
        daily_vaccinations_raw
                                                1583
        daily_vaccinations
                                                 135
        total_vaccinations_per_hundred
                                                1214
        people_vaccinated_per_hundred
                                                1615
        people fully vaccinated per hundred
                                                2277
        daily_vaccinations_per_million
                                                 135
        vaccines
                                                   0
        source name
                                                   0
        source_website
                                                   0
        dtype: int64
In [6]: | data.info()
        <class 'pandas.core.frame.DataFrame'>
        RangeIndex: 3555 entries, 0 to 3554
        Data columns (total 15 columns):
         # Column
                                                   Non-Null Count Dtype
         0 country
                                                   3555 non-null
                                                                   object
         1 iso_code
                                                   3283 non-null
                                                                   object
         2
             date
                                                   3555 non-null
                                                                   object
            total_vaccinations
                                                   2341 non-null
         3
                                                                   float64
         4 people_vaccinated
                                                   1940 non-null
                                                                   float64
            people_fully_vaccinated daily_vaccinations_raw
         5
                                                   1278 non-null
                                                                   float64
                                                   1972 non-null
                                                                   float64
         6
            daily_vaccinations
                                                   3420 non-null
                                                                   float64
            total vaccinations per hundred
         8
                                                   2341 non-null
                                                                   float64
             people_vaccinated_per_hundred
                                                   1940 non-null
                                                                   float64
         10 people_fully_vaccinated_per_hundred 1278 non-null
                                                                   float64
         11 daily_vaccinations_per_million
12 vaccines
                                                   3420 non-null
                                                                   float64
                                                   3555 non-null
                                                                   object
         13 source_name
                                                   3555 non-null
                                                                   object
         14 source_website
                                                   3555 non-null
                                                                   object
        dtypes: float64(9), object(6)
        memory usage: 416.7+ KB
        Обработка пропусков
```

```
In [7]: # Удаляем столбцы, которые не несут значимой информации data.drop(['source_name','source_website'], axis = 1, inplace = True)

In [8]: data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
         RangeIndex: 3555 entries, 0 to 3554
         Data columns (total 13 columns):
             Column
                                                     Non-Null Count Dtype
          #
          0
              country
                                                     3555 non-null
                                                                     object
          1
              iso_code
                                                     3283 non-null
                                                                     object
          2
                                                     3555 non-null
                                                                     object
              date
          3
              total vaccinations
                                                     2341 non-null
                                                                     float64
           4
              people_vaccinated
                                                     1940 non-null
                                                                     float64
              people fully vaccinated
                                                     1278 non-null
                                                                     float64
                                                     1972 non-null
                                                                     float64
           6
              daily_vaccinations_raw
              daily_vaccinations
                                                     3420 non-null
                                                                     float64
              total vaccinations per hundred
                                                     2341 non-null
                                                                     float64
              people_vaccinated_per_hundred
           9
                                                     1940 non-null
                                                                     float64
          10 people_fully_vaccinated_per_hundred 1278 non-null
                                                                     float64
          11 daily vaccinations per million
                                                     3420 non-null
                                                                     float64
                                                     3555 non-null
                                                                     object
          12 vaccines
         dtypes: float64(9), object(4)
         memory usage: 361.2+ KB
 In [9]: # Заполняем отсутствующие значения
          data['total_vaccinations'] = data['total_vaccinations'].replace(0,np.nan)
          data['total_vaccinations'] = data['total_vaccinations'].fillna(data['total_
In [10]: data.head()
         country iso_code date total_vaccinations people_vaccinated people_fully_vaccinated
Out[10]:
                             2021-
         O Albania
                                       1.508878e+06
                        ALB
                                                                0.0
                                                                                    NaN
                             01-10
                             2021-
                                       1.508878e+06
            Albania
                        ALB
                                                               NaN
                                                                                    NaN
                             01-11
                             2021-
                                     1.280000e+02
                                                              128.0
          2 Albania
                        ALB
                                                                                    NaN
                             01-12
                             2021-
                                      1.880000e+02
          3 Albania
                        ALB
                                                              188.0
                                                                                    NaN
                             01-13
                             2021-
                                      2.660000e+02
                        ALB
                                                              266.0
          4 Albania
                                                                                    NaN
                             01-14
In [11]: data.isnull().sum()
          # проверим есть ли пропущенные значения
Out[11]: country
                                                     0
                                                   272
         iso code
         date
                                                     0
         total vaccinations
                                                     0
         people_vaccinated
                                                  1615
         people_fully_vaccinated
                                                  2277
         daily_vaccinations_raw
                                                  1583
         daily_vaccinations
                                                   135
         total_vaccinations_per_hundred
                                                  1214
         people vaccinated per hundred
                                                  1615
         people_fully_vaccinated_per_hundred
                                                  2277
         daily_vaccinations_per_million
                                                   135
         vaccines
                                                     0
         dtype: int64
```

ЛР №2


Импорт библиотек

```
In [1]: import numpy as np
         import pandas as pd
         import seaborn as sns
         import matplotlib.pyplot as plt
         %matplotlib inline
         from sklearn.impute import SimpleImputer
         from sklearn.model_selection import train_test_split
In [2]: data = pd.read_csv('train.csv')
In [3]: | data.head()
           Passengerld Survived Pclass
                                          Name
                                                   Sex Age SibSp Parch
Out[3]:
                                                                            Ticket
                                                                                      Fare
                                         Braund,
         0
                     1
                             0
                                    3 Mr. Owen
                                                  male 22.0
                                                                1
                                                                       0 A/5 21171 7.2500
                                          Harris
                                        Cumings,
                                        Mrs. John
                                         Bradley
         1
                    2
                             1
                                                 female 38.0
                                                                      0 PC 17599 71.2833
                                        (Florence
                                          Briggs
                                            Th...
                                       Heikkinen,
                                                                       0 STON/02.
         2
                                                                                    7.9250
                    3
                              1
                                    3
                                           Miss. female 26.0
                                                                 0
                                                                           3101282
                                           Laina
                                         Futrelle,
                                            Mrs.
                                         Jacques
         3
                                                                            113803 53.1000
                    4
                              1
                                                 female 35.0
                                                                 1
                                                                      0
                                          Heath
                                        (Lily May
                                           Peel)
                                        Allen, Mr.
         4
                     5
                              0
                                                  male 35.0
                                                                 0
                                                                           373450 8.0500
                                    3
                                          William
                                                                       0
                                          Henry
In [4]: data['Embarked'].value_counts()
Out[4]: S
              644
              168
               77
        0
        Name: Embarked, dtype: int64
In [5]: # Кодируем признаки Pclass и Embarked в отдельные столбцы
         data = pd.get_dummies(data, columns=['Pclass', 'Embarked'])
In [6]: # Пол кодируем в 1/0
         data['IsMale']=data.Sex.replace({'female':0,'male':1})
         data.drop('Sex', axis = 1, inplace = True)
```

1 [7]:	da	ata.head()									
t[7]:		Passengerld	Survived	Name	Age	SibSp	Parch	Ticket	Fare	Cabin	Pclass
	0	1	0	Braund, Mr. Owen Harris	22.0	1	0	A/5 21171	7.2500	NaN	
	1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th	38.0	1	0	PC 17599	71.2833	C85	
	2	3	1	Heikkinen, Miss. Laina	26.0	0	0	STON/02. 3101282	7.9250	NaN	
	3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	35.0	1	0	113803	53.1000	C123	
	4	5	0	Allen, Mr. William Henry	35.0	0	0	373450	8.0500	NaN	

Масштабирование значений


```
In [8]: from sklearn.preprocessing import StandardScaler, MinMaxScaler, StandardSca
          sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['Age']])
 In [9]:
In [10]: plt.hist(data['Age'], 50)
           plt.show()
          50
          40
          30
          20
          10
                         20
                               30
                                    40
                                         50
In [11]: plt.hist(scl_data, 50)
           plt.show()
```



```
In [12]: # Удаляем столбцы, которые не несут значимой информации data.drop(['Cabin','Name','Ticket'], axis = 1, inplace = True)

In [13]: sc2 = StandardScaler() sc2_data = sc2.fit_transform(data[['Age']])

In [14]: plt.hist(sc2_data, 50)
```



i

ò

In [15]: data.head() Passengerld Survived Age SibSp Parch Fare Pclass_1 Pclass_2 Pclass_3 Embi Out[15]: 0 22.0 7.2500 1 38.0 0 71.2833 1 26.0 7.9250 1 35.0 0 53.1000 0 35.0 8.0500